


Öğretmen Kendi Referansına Karşı Ne Kadar İyi? Uzaktan Algılama Segmentasyonunda SAM Üretimli Test Maskelerinin Değerlendirme Yanılgısı

teacher_reference_bias_v1 | 2026-07-26

Öz. Otomatik pseudo-maskeler segmentation pretraining için değerlidir; ancak bağımsız test ground truth'u olarak kullanıldıklarında referansı üreten modeli kayırabilir. iSAID ve SAMRS SOTA üzerinde aynı plane sınıfı, aynı 128 test görüntüsü ve aynı SAM1/SAM2/SAM3 bbox-prompted pipeline ile kontrollü deney yapılmıştır. 126 SAMRS tile'i iSAID insan etiketli kaynaklarına piksel düzeyinde eşlenmiş ve 1.033 ortak instance için aynı tahminler iki referansa karşı ölçülmüştür. SAM1 IoU'su insan referansında 0.648, kendi pseudo referansında 0.998 bulunmuştur. Bulgular pseudo-label eğitim yararı ile benchmark validity kavramlarının ayrılması gerektiğini gösterir.



Katkılar: kaynak-sahne güvenli eşlenmiş protokol; aynı tahminle çift referanslı değerlendirme; 10.000 kümeli bootstrap; SAM1/SAM2/SAM3 GT-bbox ve YOLO-bbox ayrımı.

Anahtar kelimeler: remote sensing, Segment Anything, pseudo-label, evaluation bias, instance segmentation, öğretmen-referans yakınlığı.

1. Giriş ve 2. İlgili Çalışmalar

1. Giriş

Pixel-level uzaktan algılama annotation'ı pahalıdır. SAMRS, mevcut detection bbox'larını SAM1 prompt'u olarak kullanıp büyük ölçekli maskeler üretir. Bu yaklaşım pretraining için ölçek sağlar. Ancak aynı öğretmen kendi ürettiği maskelere karşı ölçüldüğünde, nesne sınırına uyum ile öğretmenin karar stilini yeniden üretme etkisi karışır.

İlk iSAID ve SAMRS deneylerimiz arasında büyük fark görülmesi bu soruyu doğurdu. Basit veri seti karşılaştırması yeterli değildir; görüntü zorluğu, annotation protokolü ve model referansı birlikte değişir. Bu nedenle aynı tahmini iki referansta ölçek kontrollü tasarım gerekir.

Çalışmanın katkıları: (i) iki veri setinde eşlenmiş plane protokolü, (ii) insan/pseudo eşleştirilmiş değerlendirme, (iii) kaynak-sahne bootstrap, (iv) detector ve segmenter etkisinin ayrılması, (v) üretici provenance denetimi.

2.1 SAMRS'nin amaçlanan kullanımı

SAMRS makalesi pseudo-maskeleri bağımsız bir insan benchmark'ı olarak değil, büyük ölçekli segmentation pretraining kaynağı olarak konumlandırır. Bu kullanımda öğretmen etiketiyle öğrenilen temsilen gerçek faydası, sonradan iSAID veya Potsdam gibi bağımsız insan etiketli downstream testlerde ölçülür. Bizim eleştirimiz veri üretimine değil, aynı pseudo-maskenin test ground truth'u gibi yorumlanmasına yöneliktir.

2. İlgili Çalışmalar

SAMRS, DOTA, DIOR, FAIR1M ve HRSC2016 detection annotation'larını SAM ile maskeye çevirir. Resmi SOTA-RBB kodu SAM1 ViT-H ve rotated kutunun minimum horizontal çevreleyicisi RHBox kullanır. Makalenin ana downstream iddiası pretraining sonrası bağımsız iSAID/Potsdam fine-tuning sonuçlarıdır.

Brachmann et al. pseudo-ground-truth üreten SfM/SLAM algoritmalarının benzer localisation yöntemlerini kayırabildiğini gösterir. Bu çalışma segmentation alanındaki en yakın metodolojik öncüdür. Arazo et al. confirmation bias'ı eğitim dinamiği olarak inceler; bizim problemimiz ölçüm geçerliliği problemidir.

SOPSeg ablation'ında region-adaptive magnification yaklaşık +7,75 mIoU, oriented prompt +2,29 ve edge-aware decoder +1,27 kazandırır. Bu sonuç scale-aware preprocessing ve prompt geometrisinin yeni model sürümü kadar önemli olabileceğini gösterir; bağımsız ground truth gereksinimini ortadan kaldırmaz.

2.2 Eğitim yanlılığı ve ölçüm yanlılığı

Confirmation bias, modelin kendi hatalı pseudo-label'larını eğitim sırasında pekiştirmesidir. Teacher-reference affinity ise eğitim yapılmaya bile ortaya çıkabilir: tahmin, kendisini üreten modelin sınır stiline benzeyen referansla ölçülünce skor yükselir. Bu bildiride tahmin sabit tutulduğu için ölçülen etki doğrudan değerlendirme referansından gelir.

Çalışma	Ana sorun	Bağlam
SAMRS	Pseudo-mask üretimi	Ön eğitim
Brachmann et al.	Pseudo-GT yöntem yakınlığı	Değerlendirme
Arazo et al.	Pseudo-label confirmation bias	Eğitim
Bu çalışma	Aynı tahmin, iki referans	Değerlendirme

3. Materyal ve Yöntem

3.1 Veri ve provenance

iSAID plane maskeleri insan tarafından bağımsız çizilmiş polygon'lardır; tile maskeleri kayıpsız COCO RLE'dir ve boş maske/alan denetimi sıfırdır. SAMRS SOTA plane maskeleri SAM1 ViT-H ve original DOTA RHBox prompt'larıyla üretilmiştir. Resmi 17.555 dosya ve 615.407 instance için numeric class ID, RBox ve RHBox karşılaştırılmış; geometri farkı bulunmamıştır.

İki veri setinde giriş 1024x1024, hedef plane ve test sayısı 128'dir. Testte no-overlap/overlap ile low/high mask area çarpımından dört strata vardır ve her biri 32 görüntüdür. Strata görüntü düzeyindedir: no-overlap için maksimum bbox çifti IoU=0, overlap için IoU>=0,001'dir. Low/high eşiği veri seti içi medyandır; iSAID insan maskesinde %1.671, SAMRS pseudo maskesinde %1.193'tür. Bu kırılım betimleyicidir. Split birimi tile değil parent source scene'dir; train, validation ve test kesişimi sıfırdır.

3.2 Pipeline ve değerlendirme

SAM1 ViT-H, SAM2.1 Hiera Large ve SAM3 aynı görüntü ve aynı bbox ile çalışır. iSAID GT prompt'u resmi insan bbox'ı, SAMRS GT prompt'u özgün DOTA RHBox'ıdır; SAM1 pseudo-maskeden bbox üretilmez. Üç seed ile eğitilmiş YOLO bbox ayrı koşuldur.

Ana metrik instance-level mask IoU'dur. Dice, pixel precision, pixel recall, Boundary IoU ve Success@0.50/0.75/0.90 destekleyicidir. Detector için COCO bbox AP50/AP75/AP90/AP50-95 ayrı hesaplanır. Her seed'in YOLO confidence eşiği validation setinde bbox IoU 0,50 için en yüksek F1 noktasında dondurulur; test eşik seçimine girmez. YOLO koşulunda eşleşmeyen GT boş maskeyle sıfır skor alır; eşleşmeyen detector tahmini detector AP ve image-union hesabında korunur. Instance tablosu COCO mask AP değildir.

Güven aralığı kaynak-sahne kümeli 10.000 bootstrap ile hesaplanır. Model farkları kaynak-sahne ortalamaları üzerinde eşleştirilmiş Wilcoxon testi ve Holm düzeltmesiyle incelenir.

3.3 Kontrollü ve ortak görüntü çift-referans tasarımı


Kontrollü iSAID deneyinde SAM1 GT-bbox tahmini ikinci pseudo referans olarak dondurulur. Ortak görüntü audit'inde SAMRS tile'ları iSAID kaynaklarına template matching ile geri eşlenir; yalnız template score >= 0,995 ve piksel eşitliği sağlanan tile'lar kabul edilir. SAMRS ve iSAID plane instance'ları one-to-one bbox IoU >= 0,50 ile eşlenir. Tahmin değişmez; insan ve SAM1 pseudo referans sırayla kullanılır. Bu tasarım veri seti zorluğunu sabitler. Eşleşen 1.033 tile-instance görünümü, örtüşen crop'lar nedeniyle 770 benzersiz insan-anotasyonlu uçağa karşılık gelir.

Koşul	Görüntü	Görünüm / nesne	Sahne	Referans
iSAID	128	1045	45	İnsan
SAMRS SOTA	128	1375	42	SAM1 pseudo
Ortak denetim	126	1033 / 770	35	İnsan + pseudo

4. Sonular: GT-bbox ve Referans Etkisi

Official SAMRS pseudo-mask ile bağımsız iSAID insan maskesi arasındaki ortalama IoU 0.647'tür. Referans yüksek kaliteli, fakat insan ground truth ile özdeş değildir. Aynı 1.033 tile-instance görünümü 770 benzersiz uağı aittir. Ü modelin de pseudo skoru yükselmiş, artış öğretmen SAM1 için en büyük olmuştur.

Model	İnsan IoU	SAM1 pseudo IoU	Enflasyon	%95 GA
SAM1	0.648	0.998	0.350	[0.313, 0.378]
SAM2	0.580	0.806	0.225	[0.188, 0.255]
SAM3	0.540	0.723	0.184	[0.142, 0.216]



İnsan ve pseudo referans model sırası ortak alt kümede değişmemiştir (Spearman = 1.0; Kendall tau = 1.0). Bu nedenle ana iddia ranking reversal değil, model ailesine göre farklılaşan skor enflasyonudur. Kontrollü iSAID referans değişimi de aynı yönlü sonucu verir. Benzersiz uçak başına duyarlılık analizinde SAM1/SAM2/SAM3 IoU enflasyonu 0.349/0.227/0.181'tür.

4. Detector ve YOLO-bbox Sonuçları


4.3 Üç seed YOLO detector sonuçları

Veri	Seed	Eşik	P@IoU50	R@IoU50	AP50	AP75	AP90	AP50-95
iSAID Plane	3	0.305	0.939	0.903	0.936	0.862	0.622	0.795
SAMRS SOTA Plane	3	0.700	0.940	0.896	0.953	0.871	0.279	0.725

4.4 YOLO-bbox segmentation

Veri / referans	Model	Seed	IoU	IoU std	Dice
iSAID / İnsan	SAM1	3	0.607	0.003	0.721
iSAID / İnsan	SAM2	3	0.596	0.002	0.711
iSAID / İnsan	SAM3	3	0.626	0.003	0.728
iSAID / SAM1 pseudo	SAM1	3	0.881	0.007	0.890
iSAID / SAM1 pseudo	SAM2	3	0.760	0.004	0.820
iSAID / SAM1 pseudo	SAM3	3	0.726	0.006	0.792
SAMRS / SAM1 pseudo	SAM1	3	0.869	0.014	0.881
SAMRS / SAM1 pseudo	SAM2	3	0.707	0.010	0.785
SAMRS / SAM1 pseudo	SAM3	3	0.591	0.014	0.689

GT-bbox sonuçlarının overlap × mask area katmanlarına göre dağılımı



5. Tartışma, Sınırlılıklar ve Sonuç

5. Tartışma

SAM1'in kendi pseudo referansında yaklaşık kusursuz görünmesi bağımsız insan sınırlarına göre kusursuz olduğu anlamına gelmez. Aynı tahminde yalnız referans değişimi SAM1 için yaklaşık 0,35 IoU artışı üretmiştir. SAM2 ve SAM3 de yükselmiş, fakat artış öğretmen SAM1 için daha büyüktür.

Sonuç SAMRS'nin değersiz olduğunu göstermez. Pseudo-maskeler pretraining, distillation ve weak supervision için yararlı olabilir. Downstream fayda bağımsız insan etiketli test setinde ölçülmelidir. Benchmark kullanımı üretici model, checkpoint, prompt ve insan denetimi provenance'ı gerektirir.

Remote sensing küçük nesnelerinde SOPSeg bulguları crop, magnification, oriented prompt ve boundary refinement tekniklerinin önemli olduğunu gösterir. Bu teknikler yeni deney yönüdür, ancak bağımsız referans gereksinimini çözmez.

Sınırlılıklar ve Sonuç

Ortak audit 1.375 tile-instance'ın 1.033'ünü kapsar; bunlar 770 benzersiz insan-anotasyonlu uçağa karşılık gelir. Ana deney tek plane sınıftadır. iSAID testi resmi validation havuzundan, SAMRS testi grouped source-scene ayrımından gelir; cross-dataset mutlak fark yalnız referans etkisi değildir. Annotation protokollerinin kaynak türünden bağımsız tanım ve GT bbox provenance farkları olabilir. Ortak subset'te sıralama değişmemiştir. YOLO ayarları ve epok sayısı aynı olsa da train boyutları farklı olduğundan toplam optimizasyon adımları aynı değildir; ilk üç warm-up epokundan sonra LR çizelgesi birebirdir. Çalışma pseudo-label training utility'yi doğrudan ölçmez.

Sonuç olarak öğretmen üretimli maskeler eğitim verisi ve benchmark referansı olarak aynı statüde değerlendirilmemelidir. Aynı tahmin üzerinde SAM1 için yaklaşık 0,35 IoU enflasyonu ölçülmüştür. Uzaktan algılama segmentation benchmark'ları üretici provenance'ı, bağımsız insan denetimi ve eşleştirilmiş referans duyarlılığı raporlamalıdır.

Kaynaklar

- [1] Wang et al., SAMRS, NeurIPS D&B 2023.
- [2] Kirillov et al., Segment Anything, ICCV 2023.
- [3] Zamir et al., iSAID, CVPRW 2019.
- [4] Brachmann et al., Limits of Pseudo GT, ICCV 2021.
- [5] Arazo et al., Confirmation Bias, IJCNN 2020.
- [6] Warfield et al., Segmentation Validation, 2008.
- [7] SOPSeg, arXiv:2509.03002, 2025.

Benchmark için önerilen asgari raporlama

Kontrol	Gerekli raporlama
Referans kaynağı	İnsan / pseudo ve üretici açıkça yazılmalı
Üretici provenance	Model, checkpoint, prompt ve eşikler verilmeli
Bağımsız denetim	Temsili subset insan maskesiyle ölçülmeli
Duyarlılık analizi	Aynı tahmin iki referansta raporlanmalı
Split güvenliği	Kaynak sahne kesişimi sıfır olmalı

Temel sonuç: öğretmen üretimli maskeler eğitim verisi olarak yararlı olabilir; fakat bağımsız insan referansı ile aynı epistemik statüde bir test ground truth'u değildir.