

iSAID Plane SAM1 Pseudo Reference Full Metric Document

Scope

- Veri seti iSAID, hedef sınıf plane ve model giriş çözünürlüğü 1024×1024 pikseldir.
- Test kümesi 512 görüntüdür. Dört overlap × mask-area grubunun her birinde tam 128 görüntü vardır.
- Strata tanımı gereği 512 test görüntüsünün tamamında en az bir uçak vardır; detector tablosu negatif arka plan görüntülerini içeren resmi tam benchmark değil, bu dengeli pozitif test alt kümesindeki gerçek COCO bbox değerlendirmesidir.
- No Overlap, görüntüdeki hiçbir iki GT bbox'un kesişmemesi; Overlap ise en az bir bbox çiftinin IoU değerinin 0,001 veya üstünde olmasıdır.
- Low/High Mask Area ayrımı, görüntüdeki toplam resmi iSAID insan uçak maskesi alanının veri seti için testten önce dondurulan eşiğin altında veya üstünde olmasına göre yapılır.
- SAM1, SAM2 ve SAM3 aynı görüntülerde hem GT bbox hem YOLO bbox istemiyle çalıştırılmıştır.
- YOLO detector her veri setinde ayrıca eğitilmiştir; SAM1, SAM2 ve SAM3 bu veri setlerinde yeniden eğitilmeden veya ince ayar yapılmadan yalnız bbox istemiyle kullanılmıştır.
- Detector protokolü aynı olsa da iSAID eğitim bölümü 1.571, SAMRS eğitim bölümü 2.191 görüntüdür; bu nedenle veri setleri arasındaki detector skoru farkı yalnız referans kaynağına bağlanan kontrollü bir etki değildir.
- YOLO bbox sonuçları üç bağımsız YOLO eğitiminin ortalaması $\pm$ standart sapmasıdır.
- Maske metrikleri uçak örneği düzeyinde hesaplanır; büyük nesneler küçük nesnelerin sonucunu piksel sayısıyla baskılamaz.

Metric Logic

- TP, modelin doğru biçimde nesne olarak işaretlediği pikseldir. FP, nesne olmadığı hâlde nesne diye işaretlenen; FN ise nesne olduğu hâlde kaçırılan pikseldir.
- $\text{IoU} = \text{TP} / (\text{TP} + \text{FP} + \text{FN})$. Tahmin ve referans maskenin ortak alanını birleşim alanına böler; 1 kusursuz, 0 hiç örtüşme yok demektir.
- $\text{Dice} = 2\text{TP} / (2\text{TP} + \text{FP} + \text{FN})$. IoU ile aynı davranışı farklı ölçekle ifade eder.
- $\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$. Modelin boyadığı piksellerin ne kadarının gerçekten nesne olduğunu gösterir; fazla alan boyamak precision değerini düşürür.
- $\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$. Gerçek nesne piksellerinin ne kadarının yakalandığını gösterir; eksik maske recall değerini düşürür.
- Dört ortalama maske metriği nesne örneği düzeyinde (instance-level) önce her uçak için hesaplanır, sonra bütün uçaklar eşit ağırlıkla ortalanır. Büyük uçaklar küçük uçakların sonucunu perdelemez.
- $\text{IoU} \geq 0.50/0.75/0.90$ sütunları, ilgili IoU eşiğini geçen uçak maskelerinin oranıdır. Bunlar mAP değildir ve raporda mAP gibi adlandırılmaz.

- YOLO'nun kaçırdığı bir gerçek uçak, YOLO-bbox maske tablosunda boş tahmin olarak değerlendirilir ve o örneğin maske skorları sıfır olur. Herhangi bir gerçek uçakla eşleşmeyen yanlış pozitif YOLO kutuları ise instance maske ortalamasına sahte bir referans örneği olarak eklenmez; bunların etkisi detector Precision, Recall ve mAP değerlerinde ölçülür.

- Maske tabloları her GT uçak örneğini değerlendirir; YOLO'nun eşleştiremediği GT örnekleri de boş tahmin ve sıfır skorla hesaba katılır. Bu değerlendirme gerçek COCO segmentation AP ile aynı değildir. Confidence sırasındaki bütün maskeleri ve yanlış pozitifleri kullanan uçtan uca COCO mask AP bu raporda ayrıca çalıştırılmadığı için IoU eşik oranları AP veya mAP diye yeniden adlandırılmamıştır.

- Overall tablosu 512 görüntüyü, diğer tabloların her biri 128 görüntüyü kapsar.
- GT-bbox satırları tek sabit koşuldur. YOLO-bbox satırlarındaki değerler üç ayrı YOLO eğitiminin ortalaması $\pm$ standart sapmasıdır.

Dataset Context

- Bu belge bağımsız benchmark sonucu değildir; referans kaynağı yanlılığını ölçen kontrollü deneydir.
- iSAID veri seti kaynağı: <https://captain-whu.github.io/iSAID/>
- iSAID: A Large-scale Dataset for Instance Segmentation in Aerial Images makalesi: <https://arxiv.org/abs/1905.12886>
- Görüntüler, bbox istemleri ve model tahminleri insan referansı deneyindekiyle aynıdır. Yalnız değerlendirme referansı SAM1 pseudo maskesidir.
- Bu rapordaki GT bbox, resmi iSAID insan instance anotasyonunda verilen kutudur; pseudo maskeden türetilmemiştir.
- Referansı üreten SAM1'in kendi pseudo maskelerine yüksek benzerlik göstermesi teacher-reference bias beklentisidir.
- Beş tam bağımsız iSAID insan referans tablosu ayrı full metric belgede verilmiştir. Bu belgede yalnız aynı tahminlerin referans değişimine duyarlılığını gösteren kısa karşılaştırma özeti bulunur.

YOLO Detector BBox Metrics

Not: Bu tablo yalnız YOLO detector bbox başarısını gösterir; maske metrikleri değildir. Değerler üç bağımsız eğitimin ortalaması ± standart sapmasıdır.

Detector	Images	BBox mAP50	BBox mAP75	BBox mAP90	BBox mAP50-95	BBox Precision@0.50	BBox Recall@0.50	BBox Precision@0.75	BBox Recall@0.75	BBox Precision@0.90	BBox Recall@0.90
YOLO26x (3 seed)	512	0.923 ± 0.004	0.846 ± 0.001	0.546 ± 0.018	0.764 ± 0.004	0.940 ± 0.014	0.890 ± 0.005	0.883 ± 0.013	0.836 ± 0.004	0.647 ± 0.015	0.613 ± 0.009

Overall

Referans: Kontrollü SAM1 Pseudo Referansı. Bu tablo 512 görüntüdeki 5.447 uçak örneğini kapsar. YOLO bbox değerleri üç seed ortalaması $\pm$ standart sapmadır.

Pipeline	Images	Avg IoU	Avg Dice	Avg Precision	Avg Recall	IoU $\geq$ 0.50	IoU $\geq$ 0.75	IoU $\geq$ 0.90
SAM1 GT bbox	512	1.000	1.000	1.000	1.000	1.000	1.000	1.000
SAM1 YOLO bbox	512	0.869 $\pm$ 0.004	0.878 $\pm$ 0.004	0.881 $\pm$ 0.004	0.877 $\pm$ 0.004	0.886 $\pm$ 0.004	0.875 $\pm$ 0.004	0.842 $\pm$ 0.003
SAM2 GT bbox	512	0.827	0.898	0.874	0.939	0.966	0.845	0.263
SAM2 YOLO bbox	512	0.747 $\pm$ 0.003	0.808 $\pm$ 0.004	0.789 $\pm$ 0.003	0.839 $\pm$ 0.005	0.870 $\pm$ 0.003	0.777 $\pm$ 0.001	0.250 $\pm$ 0.001
SAM3 GT bbox	512	0.795	0.871	0.875	0.880	0.955	0.793	0.151
SAM3 YOLO bbox	512	0.721 $\pm$ 0.001	0.787 $\pm$ 0.001	0.797 $\pm$ 0.001	0.788 $\pm$ 0.002	0.865 $\pm$ 0.001	0.734 $\pm$ 0.002	0.143 $\pm$ 0.002

No Overlap × Low Mask Area

Referans: Kontrollü SAM1 Pseudo Referansı. Bu tablo 128 görüntüdeki 439 uçak örneğini kapsar. YOLO bbox değerleri üç seed ortalaması ± standart sapmadır.

Pipeline	Images	Avg IoU	Avg Dice	Avg Precision	Avg Recall	IoU ≥ 0.50	IoU ≥ 0.75	IoU ≥ 0.90
SAM1 GT bbox	128	1.000	1.000	1.000	1.000	1.000	1.000	1.000
SAM1 YOLO bbox	128	0.850 ± 0.005	0.859 ± 0.005	0.859 ± 0.005	0.862 ± 0.005	0.862 ± 0.006	0.857 ± 0.007	0.834 ± 0.005
SAM2 GT bbox	128	0.795	0.875	0.850	0.925	0.929	0.779	0.173
SAM2 YOLO bbox	128	0.721 ± 0.003	0.785 ± 0.003	0.762 ± 0.003	0.821 ± 0.005	0.853 ± 0.005	0.747 ± 0.002	0.169 ± 0.006
SAM3 GT bbox	128	0.751	0.838	0.860	0.840	0.925	0.674	0.082
SAM3 YOLO bbox	128	0.685 ± 0.001	0.760 ± 0.002	0.788 ± 0.002	0.749 ± 0.002	0.843 ± 0.005	0.644 ± 0.001	0.067 ± 0.001

No Overlap × High Mask Area

Referans: Kontrollü SAM1 Pseudo Referansı. Bu tablo 128 görüntüdeki 622 uçak örneğini kapsar. YOLO bbox değerleri üç seed ortalaması ± standart sapmadır.

Pipeline	Images	Avg IoU	Avg Dice	Avg Precision	Avg Recall	IoU ≥ 0.50	IoU ≥ 0.75	IoU ≥ 0.90
SAM1 GT bbox	128	1.000	1.000	1.000	1.000	1.000	1.000	1.000
SAM1 YOLO bbox	128	0.887 ± 0.007	0.900 ± 0.007	0.909 ± 0.005	0.897 ± 0.009	0.912 ± 0.009	0.879 ± 0.011	0.833 ± 0.012
SAM2 GT bbox	128	0.820	0.889	0.896	0.900	0.957	0.826	0.310
SAM2 YOLO bbox	128	0.763 ± 0.005	0.828 ± 0.005	0.840 ± 0.005	0.831 ± 0.007	0.895 ± 0.008	0.745 ± 0.003	0.287 ± 0.003
SAM3 GT bbox	128	0.771	0.857	0.912	0.827	0.953	0.664	0.156
SAM3 YOLO bbox	128	0.711 ± 0.011	0.790 ± 0.012	0.851 ± 0.012	0.753 ± 0.012	0.880 ± 0.019	0.613 ± 0.005	0.137 ± 0.006

Overlap × Low Mask Area

Referans: Kontrollü SAM1 Pseudo Referansı. Bu tablo 128 görüntüdeki 1.708 uçak örneğini kapsar. YOLO bbox değerleri üç seed ortalaması ± standart sapmadır.

Pipeline	Images	Avg IoU	Avg Dice	Avg Precision	Avg Recall	IoU ≥ 0.50	IoU ≥ 0.75	IoU ≥ 0.90
SAM1 GT bbox	128	1.000	1.000	1.000	1.000	1.000	1.000	1.000
SAM1 YOLO bbox	128	0.858 ± 0.009	0.868 ± 0.009	0.873 ± 0.008	0.865 ± 0.010	0.879 ± 0.010	0.868 ± 0.009	0.833 ± 0.008
SAM2 GT bbox	128	0.808	0.889	0.853	0.943	0.976	0.796	0.118
SAM2 YOLO bbox	128	0.725 ± 0.007	0.792 ± 0.008	0.765 ± 0.007	0.830 ± 0.009	0.869 ± 0.010	0.744 ± 0.003	0.109 ± 0.001
SAM3 GT bbox	128	0.770	0.855	0.845	0.878	0.948	0.746	0.032
SAM3 YOLO bbox	128	0.695 ± 0.003	0.768 ± 0.003	0.769 ± 0.003	0.775 ± 0.003	0.855 ± 0.003	0.700 ± 0.006	0.026 ± 0.001

Overlap × High Mask Area

Referans: Kontrollü SAM1 Pseudo Referansı. Bu tablo 128 görüntüdeki 2.678 uçak örneğini kapsar. YOLO bbox değerleri üç seed ortalaması ± standart sapmadır.

Pipeline	Images	Avg IoU	Avg Dice	Avg Precision	Avg Recall	IoU ≥ 0.50	IoU ≥ 0.75	IoU ≥ 0.90
SAM1 GT bbox	128	1.000	1.000	1.000	1.000	1.000	1.000	1.000
SAM1 YOLO bbox	128	0.875 ± 0.003	0.882 ± 0.004	0.884 ± 0.004	0.882 ± 0.004	0.889 ± 0.004	0.882 ± 0.002	0.851 ± 0.006
SAM2 GT bbox	128	0.846	0.909	0.887	0.948	0.967	0.892	0.360
SAM2 YOLO bbox	128	0.762 ± 0.003	0.817 ± 0.004	0.797 ± 0.004	0.849 ± 0.005	0.868 ± 0.004	0.809 ± 0.003	0.345 ± 0.001
SAM3 GT bbox	128	0.823	0.889	0.887	0.901	0.966	0.872	0.238
SAM3 YOLO bbox	128	0.745 ± 0.003	0.804 ± 0.003	0.803 ± 0.002	0.812 ± 0.004	0.871 ± 0.003	0.799 ± 0.003	0.232 ± 0.002

Reference Bias Comparison

Görüntü, uçak örneği, bbox ve model tahmini aynıdır; yalnız karşılaştırılan referans maske insan etiketinden SAM1 pseudo etiketine de ğişir. Bu nedenle fark, referans kaynağına duyarlılığı doğrudan gösterir.

Model	BBox	Human IoU	SAM1 Pseudo IoU	IoU Artışı
SAM1	GT bbox	0.653	1.000	+0.347
SAM1	YOLO bbox	0.594	0.869	+0.275
SAM2	GT bbox	0.629	0.827	+0.198
SAM2	YOLO bbox	0.571	0.747	+0.176
SAM3	GT bbox	0.655	0.795	+0.140
SAM3	YOLO bbox	0.596	0.721	+0.125

No Overlap / Low Mask Area

Input + all GT bbox



Reference union



SAM1



SAM2



SAM3



Yeşil: TP | Turuncu: FP | Pembe: FN | Her GT bbox ayrı istem, maskeler birleşik görünüm


No Overlap / High Mask Area

4 instances

Input + all GT bbox



Reference union



SAM1



SAM2



SAM3



Yeşil: TP | Turuncu: FP | Pembe: FN | Her GT bbox ayrı istem, maskeler birleşik görünüm

Overlap / Low Mask Area

34 instances

Input + all GT bbox



Reference union



SAM1



SAM2




SAM3



Yeşil: TP | Turuncu: FP | Pembe: FN | Her GT bbox ayrı istem, maskeler birleşik görünüm

Overlap / High Mask Area



Yeşil: TP | Turuncu: FP | Pembe: FN | Her GT bbox ayrı istem, maskeler birleşik görünüm

Discussion

Findings

- SAM1 pseudo referansında GT-bbox Overall IoU değerleri SAM1/SAM2/SAM3 sırasıyla 1,000/0,827/0,795 olarak ölçülmüştür.
- Kontrollü pseudo referans doğrudan SAM1 GT-bbox tahmininden dondurulduğu için SAM1 GT-bbox satırı bir kimlik kontrolüdür; bu satır bağımsız segmentasyon başarısı olarak yorumlanmaz.
- SAM1 pseudo referansında YOLO-bbox Overall IoU değerleri SAM1/SAM2/SAM3 sırasıyla 0,869/0,747/0,721 olarak ölçülmüştür.
- Aynı GT-bbox tahminleri insan yerine SAM1 pseudo referansla ölçüldüğünde IoU değişimi SAM1/SAM2/SAM3 için sırasıyla 0,347/0,198/0,140 olmuştur.
- GT-bbox model sıralamasının lideri insan referansında SAM3 (0.655), SAM1 pseudo referansında SAM1 (1.000) olmuştur.
- Tam GT-bbox sıralaması insan referansında SAM3 > SAM1 > SAM2, SAM1 pseudo referansında SAM1 > SAM2 > SAM3 biçimindedir; görülen değişim pseudo referansın model seçimini etkileyebileceği riskini gösterir.
- Bu sıralamalar tablo nokta tahminleridir; birbirine yakın insan-referanslı skorlar tek başına istatistiksel üstünlük iddiası değildir.
- GT bbox yerine YOLO bbox kullanıldığında pseudo-referanslı Overall IoU kaybı SAM1/SAM2/SAM3 için sırasıyla 0,131/0,080/0,074 olmuştur.
- GT-bbox üç-model ortalamasında en yüksek alt grup Overlap × High Mask Area (0.890), en düşük alt grup No Overlap × Low Mask Area (0.849) olmuştur.
- SAM1 gt bbox koşulunda Overall Precision 1.000, Recall 1.000 olmuştur. Precision ve Recall dengelidir.
- SAM1'in kendisinin ürettiği referansa yakınlığı, gerçek insan çizimli sınır doğruluğuyla aynı şey değildir.
- Pseudo etiketler eğitim veya ön-etiketleme için kullanılabilir; ancak bağımsız test ground truth'u yerine kullanıldığında sonuç model ailesine yanlı görünebilir.